

Cheat-Sheet: Wie funktioniert ein LLM?

1. Das Kernkonzept: Die Blackbox

Ein Large Language Model (LLM) wie **Qwen** oder **GPT** ist im Grunde eine mathematische Funktion.

- **Input:** Ein Text (Prompt).
- **Verarbeitung:** Das Modell berechnet Wahrscheinlichkeiten für das nächste Wort.
- **Output:** Die Antwort der KI.

2. Das Problem: Die „Gedächtnislücke“

Standardmäßig ist eine KI **zustandslos (stateless)**.

- Sie besitzt **kein Kurzzeitgedächtnis**.
- Jede Anfrage an die API startet bei „Null“.
- **Beispiel:** Sagst du in Nachricht 1 „Ich heiße Max“, hat die KI diesen Fakt in Nachricht 2 bereits wieder vergessen.

3. Die Lösung: Das Kontext-Fenster

Um ein Gespräch zu führen, nutzen Entwickler einen Trick: Wir schicken bei jeder neuen Frage **alle bisherigen Nachrichten** (die History) wieder mit.

Merksatz: Die KI „erinnert“ sich nicht wirklich – sie liest einfach jedes Mal das gesamte Protokoll von vorne.

4. Die drei Rollen im Chat

Im Python-Code nutzen wir eine Liste von dictionaries. Jede Nachricht braucht eine Rolle (role):

Rolle	Bedeutung	Zweck
system	Die Identität	Legt fest, wie die KI sich verhalten soll (z. B. „Du bist ein Pirat“).

Rolle	Bedeutung	Zweck
user	Der Mensch	Deine Fragen oder Anweisungen an die KI.
assistant	Die KI	Die vorherigen Antworten, die die KI gegeben hat.

Wichtige Begriffe

- **Token:** Ein Wort oder Wortteil. KIs rechnen nicht in Wörtern, sondern in Zahlenwerten für diese Token.
- **Parameter:** Die „Stellschrauben“ im Gehirn der KI (unser Modell Qwen2.5-1.5B hat 1,5 Milliarden davon).
- **Open Source:** Modelle wie Qwen sind frei verfügbar. Wir können sie lokal ausführen, ohne dass unsere Daten (Prompts) an Firmen wie OpenAI gesendet werden.