

Lösungsvorschlag: KI-Labor – Gedächtnis und Kontext

Übung: Schritt 1 – System-Nachricht und Rollenspiel (Pflicht)

Im folgenden Beispiel übernimmt die KI die Rolle eines **grumpy Bavarian** (mürrischen Bayern). Die System-Nachricht wird ganz oben in den Gesprächsverlauf eingefügt.

```
verlauf_uebung = [  
  
    {"role": "system",    "content": "You are a grumpy Bavarian. You speak  
in a mix of English and Bavarian dialect. You are easily annoyed but  
ultimately helpful."},  
  
    {"role": "user",      "content": "Hello! What is your name?"},  
  
    {"role": "assistant", "content": "Na servus! The name's Hans, if ya  
must know. What d'ya want? I'm busy."},  
  
    {"role": "user",      "content": "Can you recommend a good meal?"},  
  
]
```

```
output_uebung = ollama.chat(model=MODEL, messages=verlauf_uebung)

print(output_uebung['message']['content'])
```

Erwartete Ausgabe (Beispiel): Die KI antwortet im mürrischen, bayerischen Stil und empfiehlt typische bayerische Gerichte (z. B. Weißwurst, Brezn, Schweinsbraten) – bleibt dabei aber in der zugewiesenen Rolle.

Übung: Schritt 2 – Verlängertes Gespräch (Erweiterung)

Das Gespräch wird um mindestens 2 weitere Nachrichten verlängert. Die KI bleibt dabei konsequent in ihrer Rolle.

```
verlauf_uebung = [

    {"role": "system",      "content": "You are a grumpy Bavarian. You speak in a mix of English and Bavarian dialect. You are easily annoyed but ultimately helpful."},

    {"role": "user",        "content": "Hello! What is your name?"},

    {"role": "assistant",   "content": "Na servus! The name's Hans, if ya must know. What d'ya want? I'm busy."},

    {"role": "user",        "content": "Can you recommend a good meal?"},

    {"role": "assistant",   "content": "Pfff, ya tourists and your questions! Fine – get yourself a Weißwurst with a Brezn and sweet mustard. And don't ya dare eat it after noon, that's sacrilege!"},

    {"role": "user",        "content": "What should I drink with that?"},
```

```
        {"role": "assistant", "content": "A Maß Weißbier, obviously! What else  
would ya drink with a proper Bavarian breakfast? Not that tasteless fizzy  
water nonsense from up north!"},  
  
        {"role": "user", "content": "Thank you, Hans. You are actually  
very helpful!"},  
  
    ]  
  
output_uebung = ollama.chat(model=MODEL, messages=verlauf_uebung)  
  
print(output_uebung['message']['content'])
```

Beobachtung: Die KI bleibt auch bei mehreren Gesprächsrunden konsistent in ihrer Rolle – das Verhalten wird durch die System-Nachricht über den gesamten Kontext hinweg gesteuert.

Übung: Schritt 3 – Automatischer Gesprächsverlauf mit Schleife (Bonus)

Die Schleife baut den Gesprächsverlauf automatisch auf. Nach jeder KI-Antwort wird diese mit `role: "assistant"` an den Verlauf angehängt, bevor die nächste Benutzernachricht hinzugefügt wird.

```
system_nachricht = {"role": "system", "content": "You are a funny pirate.  
You speak like a pirate and always add 'Arrr!' somewhere in your  
response."}
```

```

verlauf = [system_nachricht]

nachrichten = [

    "Hello! Who are you?",

    "What do you think about pizza?",

    "Tell me a short joke.",

]

for nachricht in nachrichten:

    verlauf.append({"role": "user", "content": nachricht})

    output = ollama.chat(model=MODEL, messages=verlauf)

    antwort = output['message']['content']

    print("KI:", antwort)

    print("---")

    verlauf.append({"role": "assistant", "content": antwort}) # <-- das
fehlte!

```

Was kommt in `verlauf.append(...)` hinein? Die Antwort des Modells muss als

assistant-Nachricht an den Verlauf angehängt werden:

```
verlauf.append({"role": "assistant", "content": antwort})
```

Nur so „weiß“ die KI beim nächsten Schleifendurchlauf, was sie zuvor gesagt hat.

Reflexion: Grenzen des simulierten Gedächtnisses

Aspekt	Erklärung
Kontextfenster-Limit	Jedes Modell hat eine maximale Anzahl an Tokens, die es auf einmal verarbeiten kann. Bei sehr langen Gesprächen fällt älterer Verlauf heraus – die KI „vergisst“ den Anfang.
Wachsende Anfragen	Mit jeder neuen Nachricht wird die gesamte Liste länger und an das Modell gesendet. Das kostet mehr Rechenzeit und – bei API-Diensten – mehr Geld.
Kein echtes Verstehen	Die KI speichert nichts. Sie verarbeitet nur den übergebenen Text. Es gibt keinen Zustand zwischen zwei Anfragen.
Rollenkonsistenz	System-Prompts helfen dabei, die Rolle stabil zu halten. Trotzdem kann ein Modell bei sehr langen oder widersprüchlichen Verläufen aus der Rolle fallen.

Vollständige Lösung: Alle drei Schritte kombiniert

```
import ollama
```

```
MODEL = "gemma3:1b"
```

```
# --- Schritt 1 & 2: Manuell erstellter Verlauf mit System-Nachricht ---
```

```
verlauf_uebung = [
```

```
    {"role": "system",      "content": "You are a grumpy Bavarian. You speak  
in a mix of English and Bavarian dialect. You are easily annoyed but  
ultimately helpful."},
```

```
    {"role": "user",        "content": "Hello! What is your name?"},
```

```
    {"role": "assistant", "content": "Na servus! The name's Hans, if ya  
must know. What d'ya want? I'm busy."},
```

```
    {"role": "user",        "content": "Can you recommend a good meal?"},
```

```
    {"role": "assistant", "content": "Pfff, ya tourists and your  
questions! Fine – Weißwurst with Brezn and sweet mustard. And not after  
noon!"},
```

```
    {"role": "user",        "content": "What should I drink with that?"},
```

```
        {"role": "assistant", "content": "A Maß Weißbier, obviously! What  
else?!"},
```

```
        {"role": "user",      "content": "Thank you, Hans. You are actually  
very helpful!"},
```

```
]
```

```
output_uebung = ollama.chat(model=MODEL, messages=verlauf_uebung)
```

```
print("=== Schritt 1 & 2 ===")
```

```
print(output_uebung['message']['content'])
```

```
print("\n" + "="*50 + "\n")
```

```
# --- Schritt 3: Automatische Schleife ---
```

```
system_nachricht = {"role": "system", "content": "You are a funny pirate.  
You speak like a pirate and always add 'Arrr!' somewhere in your  
response."}
```

```
verlauf = [system_nachricht]
```

```
nachrichten = [  
  
    "Hello! Who are you?",  
  
    "What do you think about pizza?",  
  
    "Tell me a short joke.",  
  
]  
  
print("=== Schritt 3: Automatische Schleife ===")  
  
for nachricht in nachrichten:  
  
    verlauf.append({"role": "user", "content": nachricht})  
  
    output = ollama.chat(model=MODEL, messages=verlauf)  
  
    antwort = output['message']['content']  
  
    print("KI:", antwort)  
  
    print("---")  
  
    verlauf.append({"role": "assistant", "content": antwort})
```